LABORATORIO_03

MATERIA: INTELIGENCIA ARITIFICIAL

ESTUDIANTE: Alvarez Alain Jonathan

AÑO:2024

Carrera: Ing. en Diseño y Animación Digital

1.- RESUMEN EXPLICANDO LO TRABAJADO

Lo primero que hicimos fue importar lo que serían las librerías que usaríamos, mas que nada la librería de Pandas y enlazar nuestro drive

Luego importamos lo que seria nuestro dataset seleccionado en clases, de este escogemos nuestras X y nuestra Y, de esto dividimos nuestros datos en 80% entrenamiento y el otro 20% prueba

Jonathan.ipynb ☆

e ejecución Herramientas Ayuda Se han guardado todos los cambios

Comentario Comparti

+ Código + Texto

RAM Disco

```
import numpy as np
from sklearn.model_selection import train_test_split

# Cargar datos del archivo CSV limpio
data = pd.read_csv('/content/gdrive/MyDrive/binario_limpio.csv', delimiter=',')  # Ajustar la ruta si es necesario

# Asignar X con las columnas 1, 2, 3, 4, 5, 6 y y con la columna 0
X = data.iloc[:, [1, 2, 3, 4, 5, 6]].values
y = data.iloc[:, 0].values

# Dividir los datos en entrenamiento (80%) y prueba (20%)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Mostrar dimensiones de los conjuntos de datos
print("Dimensiones de X_train:", X_train.shape)
print("Dimensiones de X_test:", X_test.shape)
print("Dimensiones de y_train:", y_train.shape)
print("Dimensiones de y_test:", y_test.shape)
```

```
Dimensiones de X_train: (202928, 6)
Dimensiones de X_test: (50733, 6)
Dimensiones de y_train: (202928,)
Dimensiones de y_test: (50733,)
```

Graficamos nuestros datos

```
def plotData(X, y):
    # Gráfica los puntos de datos X y y en una nueva figura.
    # Grafica los puntos de datos con * para los positivos y o para los negativos.

    # Crea una nueva figura
    fig = plt.figure()

    # Encuentra índices de ejemplos positivos y negativos
    pos = y == 1
    neg = y == 0

    # Grafica ejemplos
    plt.plot(X[pos, 0], X[pos, 1], 'k*', lw=2, ms=10)
    plt.plot(X[neg, 0], X[neg, 1], 'ko', mfc='y', ms=8, mec='k', mew=1)
```

Se llama a la función implementada para mostrar los datos cargados:

```
[10] plotData(X_train, y_train)
     # Adiciona etiquetas para los ejes
     plt.xlabel('Característica 1')
     plt.ylabel('Característica 2')
     plt.legend(['Clase 1', 'Clase 0'])
     plt.show()
```

Mostramos la grafica

```
plotData(X_train, y_train)
# Adiciona etiquetas para los ejes
plt.xlabel('Característica 1')
plt.ylabel('Característica 2')
plt.legend(['Clase 1', 'Clase 0'])
plt.show()
```

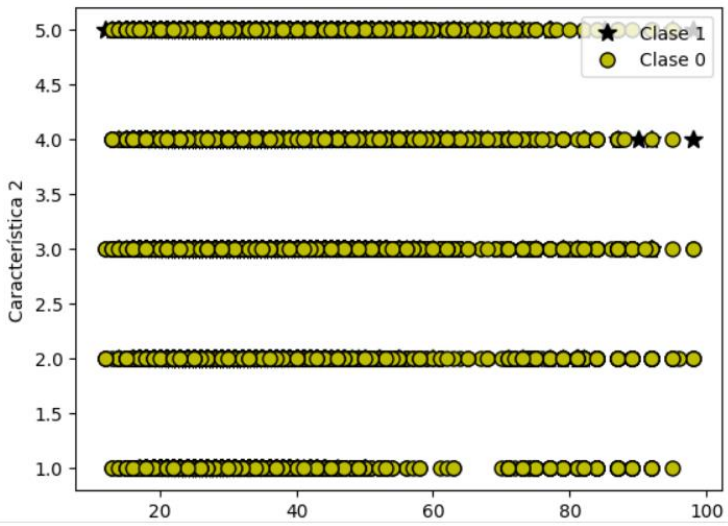

Aplicamos las formulas aprendidas en clases

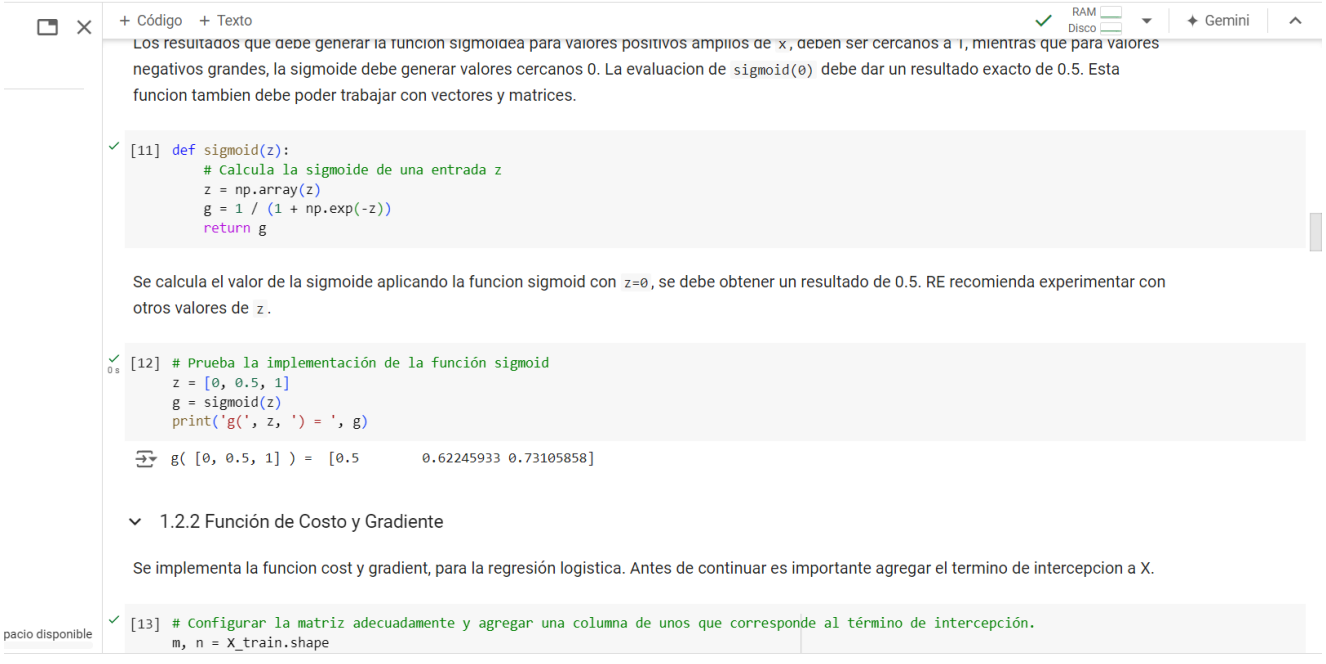

Damos a Alpha un valor y damos un número determinado de interacciones y luego modificamos el X_arrary según nuestro dataset

```
[15]     return theta, J_history

# Elegir algún valor para alpha (probar varias alternativas)
alpha = 0.001
num_iters = 100

# Inicializa theta y ejecuta el descenso por el gradiente
theta = np.zeros(n + 1)
theta, J_history = descensoGradiente(theta, X_train, y_train, alpha, num_iters)

# Gráfica la convergencia del costo
plt.plot(np.arange(len(J_history)), J_history, lw=2)
plt.xlabel('Número de iteraciones')
plt.ylabel('Costo J')

# Muestra los resultados del descenso por el gradiente
print('Theta calculado por el descenso por el gradiente:', theta)

# Verificar predicción para un conjunto específico
X_array = [1, 80, 46, 70, 60, 50, 85]  # Ajustar según características
aprueba = sigmoid(np.dot(X_array, theta))

print('Para un conjunto de características dado, la probabilidad predicha es: {:.2f}'.format(aprueba))
```

```
Theta calculado por el descenso por el gradiente: [-0.0036882  -0.0723971  -0.0008557   0.00196298  0.02566578 -0.00927402
 -0.03034503]
Para un conjunto de características dado, la probabilidad predicha es: 0.00
```

Graficamos

```
Theta calculado por el descenso por el gradiente: [-0.0036882  -0.0723971  -0.0008557   0.00196298  0.02566578 -0.00927402
 -0.03034503]
Para un conjunto de características dado, la probabilidad predicha es: 0.00
```

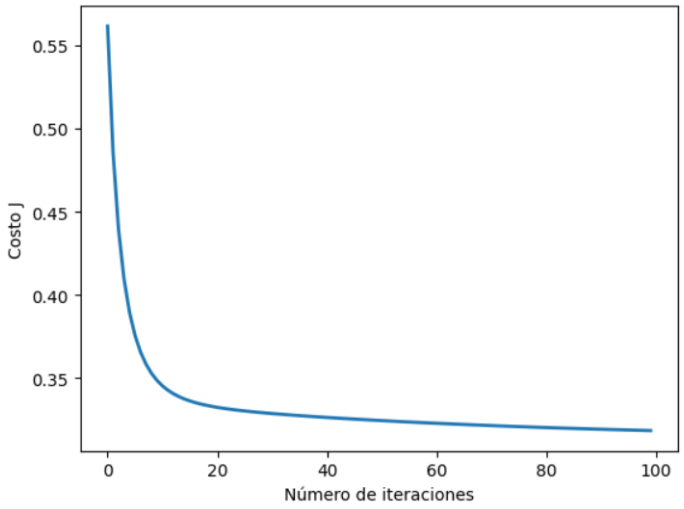

En la siguiente formula cambiamos las variables de test_theta , gradiante en theta inicial de acuerdo a nuestro dataset.

Se prueba la funcion `costFunction` utilizando dos casos de prueba para θ.

```
[ ] # Inicialización de parámetros de ajuste
    initial_theta = np.zeros(n + 1)
    cost, grad = costFunction(initial_theta, X_train, y_train)

    print('Costo en theta inicial (zeros): {:.3f}'.format(cost))
    print('Gradiente en theta inicial (zeros):', grad)
```

```
Costo en theta inicial (zeros): 0.693
Gradiente en theta inicial (zeros): [ 0.4054098  11.40110532  0.93795583  1.1489617   1.25925205  3.05923776
  2.54001419]
```

```
[ ] # Calcula y muestra el costo y el gradiente con valores de theta diferentes a cero
    test_theta = np.array([-24, 0.2, 0.2, 0.1, 0.3, 0.4, 0.5])  # Ajustar dimensiones si es necesario
    cost, grad = costFunction(test_theta, X_train, y_train)

    print('Costo en theta de prueba: {:.3f}'.format(cost))
    print('Gradiente en theta de prueba:', grad)
```

```
Costo en theta de prueba: 0.773
Gradiente en theta de prueba: [-0.0658074  -1.72978066 -0.2005593  -0.01194694 -0.05307026 -0.69049167
 -0.33246881]
```

Luego usamos los siguientes códigos para un parámetros de aprendizaje usando scipy.optimize

```
# Establecer las opciones para optimize.minimize
options = {'maxiter': 1000}

# Revisar la documentación de scipy's optimize.minimize para mayor descripción de los parámetros
res = optimize.minimize(costFunction,
                        initial_theta,
                        (X_train, y_train),
                        jac=True,
                        method='TNC',
                        options=options)

# La propiedad `fun` del objeto devuelto por `OptimizeResult` contiene el valor del costFunction de un theta optimizado
cost = res.fun

# Theta optimizada está en la propiedad `x`
theta = res.x

# Imprimir theta optimizada
print('Costo con un valor de theta encontrado por optimize.minimize: {:.3f}'.format(cost))
print('Theta optimizada:', theta)
```

```
<ipython-input-21-23a2650de068>:5: OptimizeWarning: Unknown solver options: maxiter
  res = optimize.minimize(costFunction,
Costo con un valor de theta encontrado por optimize.minimize: 0.258
Theta optimizada: [-7.24504530e+00  1.65106640e-02  6.62394172e-01  4.42354966e-03
  4.93714565e-03  3.02202179e-01 -3.62999401e-02]
```

ible

```
def plotDecisionBoundary(plotData, theta, X, y):
    """
    Grafica los puntos X y Y en una nueva figura con un límite de decisión definido por theta.
    Grafica los puntos con * para los ejemplos positivos y con o para los ejemplos negativos.
    """
    # Hacer que theta sea un arreglo numpy
    theta = np.array(theta)

    # Graficar los datos (recordar que la primera columna en X es la intercepción)
    plotData(X[:, 1:3], y)  # Ajusta para graficar las dos primeras características

    if X.shape[1] <= 3:
        # Solo se requieren 2 puntos para definir una línea, para lo cual se eligen dos puntos finales
        plot_x = np.array([np.min(X[:, 1]) - 2, np.max(X[:, 1]) + 2])

        # Calcular la línea límite de decisión
        plot_y = (-1. / theta[2]) * (theta[1] * plot_x + theta[0])

        # Graficar y ajustar los ejes para una mejor visualización
        plt.plot(plot_x, plot_y, label='Límite de decisión')
        plt.xlim([np.min(X[:, 1]) - 5, np.max(X[:, 1]) + 5])
        plt.ylim([np.min(X[:, 2]) - 5, np.max(X[:, 2]) + 5])
        plt.legend()
        plt.show()
```

Luego con eso graficamos y empezamos a hacer la evaluación de la regresión logística usando los códigos que nos enseño en clases

Moficamos lo que es prob con datos en relación a nuestro datset, luego logramos encontrar lo que es nuestra probabilidad que es 1 y nuestra precisión de entrenamiento y prueba.